Linguaggi di Programmazione

Introduzione ai linguaggi naturali, artificiali e formali

Roberto Gorrieri

Alma Mater Studiorum - Università di Bologna

Introduzione ai linguaggi naturali e artificiali

Linguaggi (naturali o artificiali)

La descrizione di un linguaggio avviene su tre dimensioni:

- **Sintassi**: regole di formazione - quando una frase è corretta? - relazione tra segni
- **Semantica**: attribuzione di significato - cosa significa una frase corretta? - relazione tra segni e significato
- **Pragmatica**: in quale modo le frasi corrette e sensate sono usate? relazione tra segni, significato ed utente

Per un linguaggio eseguibile, si aggiunge anche un'ulteriore dimensione:

- **Implementazione**: come eseguire una frase corretta, rispettandone la semantica.

Sintassi

Aspetto Lessicale: specificare le parole che si possono usare.

- Descrizione del lessico:
  - Dizionari (per i linguaggi naturali)
  - Strutture più complesse per i linguaggi artificiali
- Errore: vocabolo inesistente, ad esempio "can*u*" (in italiano), "th*o*n" (in inglese),...

Aspetto Grammaticale: specificare come frasi corrette si possono costruire con il lessico.

- Descrizione attraverso regole grammaticali (in numero finito)
  - Le frasi generabili sono infinite
- Errore: frase scorretta, ad esempio "*La* cane abbaia*no*" (lessico corretto, ma frase grammaticalmente scorretta)

Semantica

Per il lessico, se conosco a quale linguaggio appartiene la parola (ad es., *fame*), ci sono i dizionari (che specificano il significato di ogni parola).

Per le frasi, devo sapere:

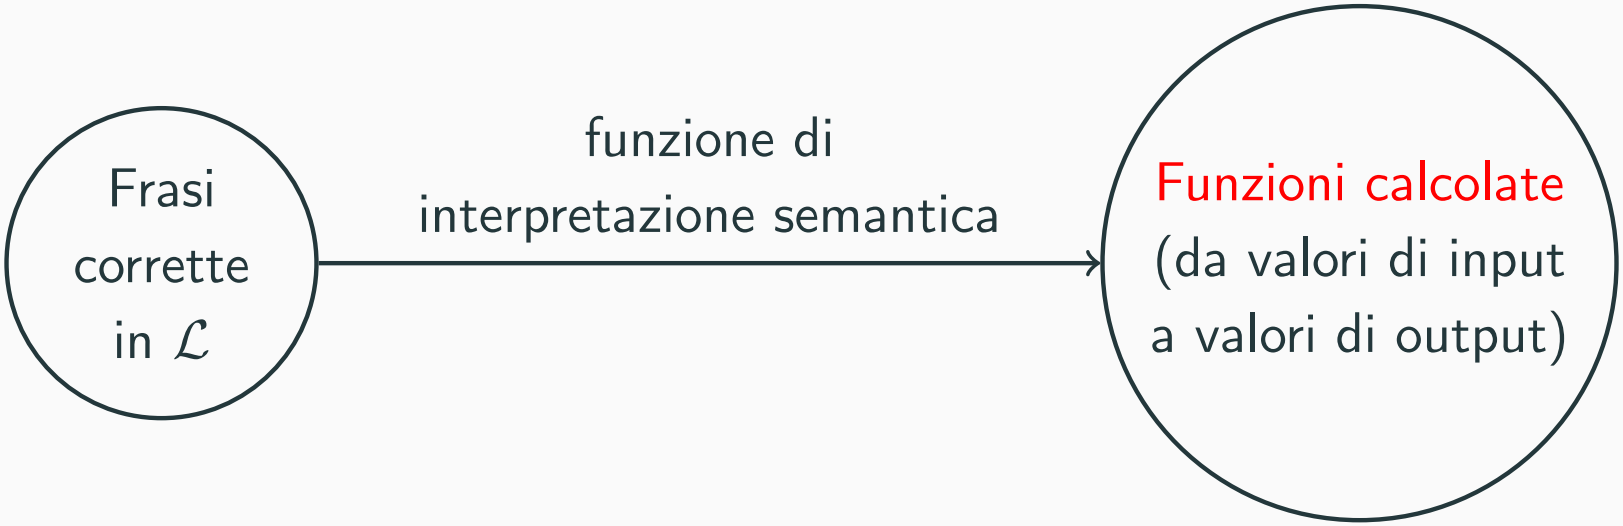
- A quale linguaggio la frase appartiene. Ad esempio:
  - I vitelli dei romani sono belli *(italiano o latino?)*
  - Va, o Vitellio, al suono del dio romano della guerra *(significato della frase latina)*
- Su quale linguaggio basarmi per dare significato:
  - Bisogna basarsi su qualcosa di noto, cioè che non abbia a sua volta bisogno di essere spiegato.

Semantica

Linguaggio naturale:



Linguaggio di programmazione (sequenziale) $\mathcal{L}$:



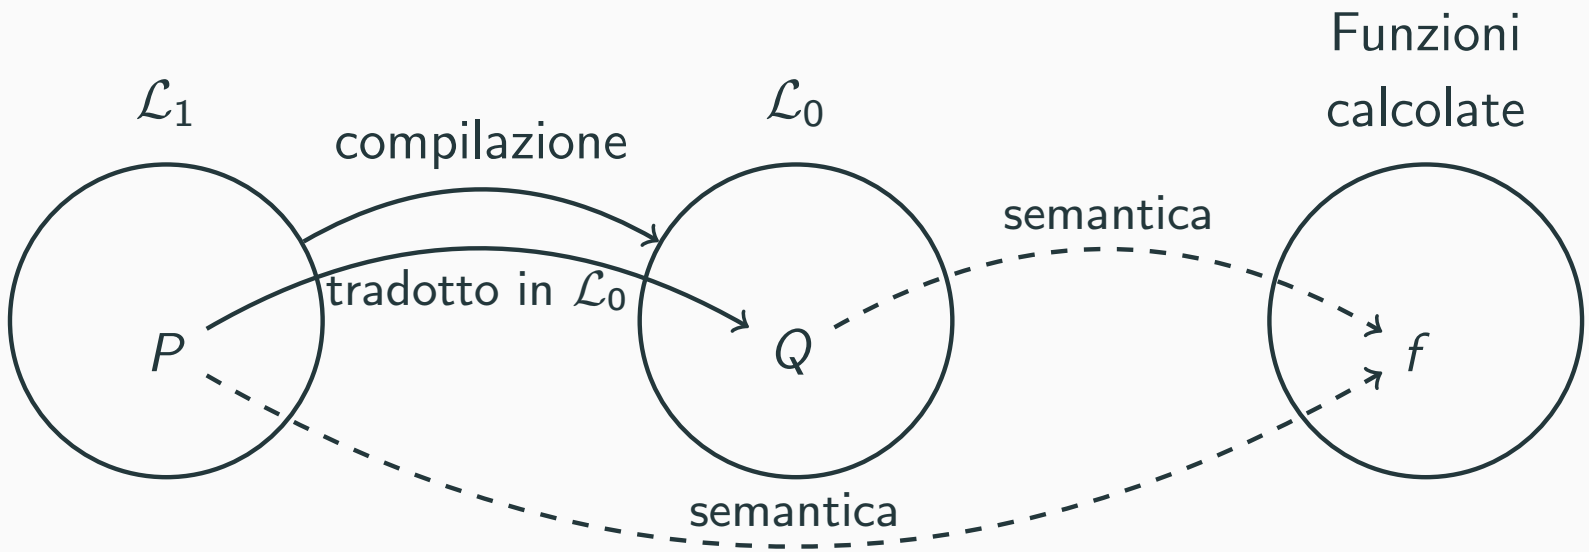
Pragmatica

Insieme di regole che guidano l'uso, ad esempio

- Nei linguaggi naturali (italiano): Usare il "lei " anziché il "tu" quando ci si rivolge ad uno sconosciuto.
- Nei linguaggi di programmazione: Evitare di usare istruzioni `goto` perchè rendono incomprensibili i programmi.

Implementazione

Eseguire una frase sintatticamente corretta rispettandone la semantica.



Programma sorgente `P`

```
I := I+1
```

Programma tradotto `Q`

```
MOV I R0
ADD 1 R0
MOV R0 I
```

La semantica di `P` è la funzione f, che è pure la semantica del programma compilato `Q`:

l'implementazione `Q` di `P` preserva la semantica di `P`!

Introduzione ai linguaggi formali

Lessico e Frasi di un Linguaggio

- **Alfabeto**: a,b,c,... (insieme tipicamente finito di simboli o caratteri)
- **Lessico**: insieme di sequenze finite (dette *parole* o *stringhe*) costruite con caratteri (simboli) dell'alfabeto (nei linguaggi naturali è finito, nei linguaggi artificiali può essere infinito contabile)
- **Frasi**: insieme di sequenze finite costruite con parole del lessico (tipicamente infinito contabile)

N.B.: Il **Lessico** è un **Alfabeto** per **Frasi**!
Allora, proviamo ad astrarci per definire cosa sia un linguaggio formale.

Linguaggio Formale

- Un **alfabeto** A è un insieme finito i cui elementi sono detti simboli.
- Una **parola** su un alfabeto A è una sequenza finita di simboli in A.
- Un **Linguaggio formale** L su A è un insieme (possibilmente infinito) di parole su alfabeto A.

Un linguaggio formale L su un alfabeto A è un sottoinsieme di A^* (cioè $L \subseteq A^*$), dove A^* è l'insieme di tutte le possibili parole su alfabeto A:

- $A^* = \bigcup_{n \geq 0} A^n$, dove $A^0 = \{\epsilon\}$
  - ϵ è la parola vuota, sequenza senza alcun simbolo
- e $A^{n+1} = A \cdot A^n$ $(n >= 0)$
  - con $A \cdot A^n = \{aw | a \in A, w \in A^n\}$
  - dove $\cdot$ è l'operatore di concatenazione.

Osservazione

A^* è un insieme infinito contabile. Dato un ordinamento $<$ sui simboli di A (ad esempio, l'usuale ordinamento $a < b < c < ...$), possiamo elencare tutte le parole in A^* come segue:

- Prima elenco la parola vuota ϵ (di lunghezza 0, ovvero elenco A^0)
- Poi elenco le parole di lunghezza 1 secondo l'ordinamento $<$: $a, b, c, ...$ (ovvero elenco A^1)
- Poi elenco le parole in A^2 secondo $<$: $aa, ab, ac, ...ba, bb, ...$
- Poi elenco le parole in A^3 secondo $<$
- e così via...

Nota che per ogni k, A^k è un insieme finito, con cardinalità n^k se $|A| = n$. In questo modo metto in corrispondenza biunivoca $\mathbb{N}$ con A^*.

Se ammettessimo alfabeti con un numero infinito di simboli?
Ovvero, se $A = \{a_0, a_1, a_2, \dots\}$, allora A^* sarebbe ancora contabile? Cioè sarebbe possibile elencare tutte le parole in A^*? Non posso usare il procedimento di prima: A^1 è infinito e non comincerei mai ad elencare A^2

Eppure... sì!

A^* può essere messo in corrispondenza biunivoca con $\mathbb{N}$ in base a queste osservazioni:

- $\mathbb{N} \times \mathbb{N}$ è numerabile (dove-tailing: riempimento per diagonali)
  - $f^2 : \mathbb{N} \times \mathbb{N} \to \mathbb{N}$ biunivoca
- $\mathbb{N}^k$ è numerabile ($f^k : \mathbb{N}^k \to \mathbb{N}$ biunivoca)
  - $f^k(x_1, x_2, ..., x_k) = \ \textit{if} \ \ k = 2 \ \ \textit{then} \ \ f^2(x_1, x_2) \ \ \textit{else}$
    $f^2(x_1, f^{k-1}(x_2, ..., x_k)) = f^2(x_1, f^2(x_2, \dots f^2(x_{k-1}, x_k)\dots))$
- $\mathbb{N}^* = \bigcup_{k \geq 0} \mathbb{N}^k$ è numerabile ($f : \mathbb{N}^* \to \mathbb{N}$ biunivoca)
  - $f(x_1, ..., x_k) = f^2(k, f^k(x_1, ..., x_k))$

Linguaggio Formale - Dove Tailing

$x_2 \backslash x_1$	0	1	2	3	4	5	$\cdots$
0	0	1	3	6	10	15	$\cdots$
1	2	4	7	11	16		$\cdots$
2	5	8	12	17			$\cdots$
3	9	13	18				$\cdots$
4	14	19					$\cdots$
5	20						$\cdots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\ddots$

- **funzione di codifica** $f^2 : \mathbb{N} \times \mathbb{N} \to \mathbb{N}$
- **funzioni di decodifica** $f_1^2 : \mathbb{N} \to \mathbb{N}$ e $f_2^2 : \mathbb{N} \to \mathbb{N}$ tali che
  - $f_1^2(f^2(x_1, x_2)) = x_1$
  - $f_2^2(f^2(x_1, x_2)) = x_2$

Linguaggio Formale - Dove Tailing

La funzione di codifica $f^2 : \mathbb{N} \times \mathbb{N} \to \mathbb{N}$ è

$$f^2(x_1, x_2) = \frac{(x_1+x_2)(x_1+x_2+1)}{2} + x_2$$

Ad esempio, $f^2(2,1) = \frac{3 \cdot 4}{2} + 1 = 7$.

- $x_1 + x_2$ è il numero di diagonali completamente riempite al di sotto della entry (x_1, x_2)
- la somma di tutti gli elementi in queste $x_1 + x_2$ diagonali è $1 + 2 + 3 + ... + (x_1 + x_2) = \frac{(x_1+x_2)(x_1+x_2+1)}{2}$ (metodo di Gauss)

Per la funzione di decodifica, bisogna trovare

$$K_x = max\{i | \frac{i \cdot (i+1)}{2} \leq x\}$$

così che $k_x = x_1 + x_2$, quindi $x_2 = x - \frac{k_x(k_x+1)}{2}$ e $x_1 = k_x - x_2$.
Ad esempio, $f_1^2(7) = 2$ perché $k_7 = 3$ (infatti $\frac{3 \cdot 4}{2} \leq 7$), perciò $x_2 = 7 - \frac{3 \cdot 4}{2} = 1$ e $x_1 = 3 - 1 = 2$.

Notazioni e Definizioni Ausiliarie

Lunghezza, concatenazione

- **Lunghezza di una parola** (o stringa):

$$|\epsilon| = 0$$
$$|aw| = 1 + |w|$$

esempio: $|abc| = 3$

- **Concatenazione** x concatenata ad y, indicata come xy, è la parola ottenuta giustapponendo x e y.

$$w = xy \iff \begin{cases} |w| = |x| + |y| \\ w(j) = x(j) \text{ per } 1 \leq j \leq |x| \\ w(|x| + j) = y(j) \text{ per } 1 \leq j \leq |y| \end{cases}$$

dove $w(j)$ indica il j-esimo simbolo di w.

Leggi della concatenazione:

- $x(yz) = (xy)z$ (associatività)
- $x\epsilon = x = \epsilon x$ (ϵ elemento neutro)

Notazioni e Definizioni Ausiliarie

Sottostringa, suffisso, prefisso, potenza, linguaggio

- v è **sottostringa** di una stringa w se e solo se $\exists x, y \in A^*$ (che possono essere anche ϵ) tali che $w = xvy$
  - Ogni stringa è sottostringa di sè stessa
  - ϵ è sottostringa di ogni stringa
- v è **suffisso** di w se e solo se $\exists x \in A^*$ tale che $w = xv$
- v è **prefisso** di w se e solo se $\exists x \in A^*$ tale che $w = vx$
- **Potenza n-esima** di una stringa w:

$$w^0 = \epsilon$$
$$w^{n+1} = ww^n$$

  esempio: $(ab)^1 = ab$, $(ab)^2 = abab$, $(ab)^3 = ababab$
- **Linguaggio L su alfabeto** A: $L \subseteq A^*$. Ad esempio, sia $A = \{a\}$:
  - $\emptyset, \{\epsilon\}, \{a, aa\}$ sono linguaggi finiti.
  - $L_1 = \{a, aa, aaa, ...\} = \{a^n | n \geq 1\} = A^* \setminus \{\epsilon\}$ e $L_2 = \{a, aaa, aaaaa...\} = \{a^{2n+1} | n \geq 0\}$ sono linguaggi infiniti.

Operazioni su linguaggi

- **Complemento** $\overline{L} = \{w \in A^* | w \notin L\} = A^* \setminus L$
- **Unione** $L_1 \cup L_2 = \{w | w \in L_1 \vee w \in L_2\}$
- **Intersezione** $L_1 \cap L_2 = \{w | w \in L_1 \wedge w \in L_2\}$,
- **Concatenazione** $L_1 \cdot L_2 = \{w_1 w_2 | w_1 \in L_1 \wedge w_2 \in L_2\}$,
  - **Prodotto Cartesiano** $L_1 \times L_2 = \{(w_1, w_2) | w_1 \in L_1 \wedge w_2 \in L_2\}$

  La concatenazione non è il Prodotto Cartesiano! Ad esempio:

$$L_1 = \{a, ab\} \text{ e } L_2 = \{bc, c\}$$

$$L_1 \cdot L_2 = \{abc, ac, abbc\} \text{ (N.B.: } a \cdot bc = ab \cdot c = abc)$$

$$L_1 \times L_2 = \{(a, bc), (a, c), (ab, bc), (ab, c)\}$$

Esempi su concatenazione

- $L_1 = \{a^n \mid n \geq 0\}$ e $L_2 = \{b\}$
  $$L_1 \cdot L_2 = \{a^n b \mid n \geq 0\}$$
- $L_1 = \{a^{2n} \mid n \geq 0\}$ e $L_2 = \{b^n \mid n \geq 0\}$
  $$L_1 \cdot L_2 = \{a^{2n} b^m \mid n, m \geq 0\}$$
- $L_1 = \{a^n b^n \mid n \geq 0\}$ e $L_2 = \{b^n \mid n \geq 0\}$
  $$L_1 \cdot L_2 = \{a^n b^{n+m} \mid n, m \geq 0\} = \{a^n b^m \mid m \geq n \geq 0\}$$
- $L_1 = \{a^n \mid n \geq 1\}$ e $L_2 = \{a^n b^n \mid n \geq 0\}$
  $$L_1 \cdot L_2 = \{a^{n+m} b^m \mid n \geq 1, m \geq 0\} = \{a^n b^m \mid n > m \geq 0\}$$
- $L_1 = \{ab^n \mid n \geq 1\}$ e $L_2 = \{a, c\} \cup \{b^n \mid n \geq 1\}$
  $$L_1 \cdot L_2 = \{ab^n a \mid n \geq 1\} \cup \{ab^n c \mid n \geq 1\} \cup \{ab^n \mid n \geq 2\}$$
- $A = \{0, 1\}$ e $L_1 = \{w \in A^* \mid w$ contiene un numero pari di $0\}$ e $L_2 = \{w \in A^* \mid w = 0y, y \in \{1\}^*\}$
  $$L_1 \cdot L_2 = \{w \in A^* \mid w \text{ contiene un numero dispari di } 0\}$$

Altre operazioni su linguaggi

- **Potenza**

$$L^0 = \{\epsilon\}$$
$$L^{n+1} = L \cdot L^n$$

- **Chiusura/Stella di Kleene/Ripetizione/Iterazione**

$$L^* = \bigcup_{n \geq 0} L^n$$
$$L^+ = \bigcup_{n \geq 1} L^n \text{ (chiusura positiva)}$$

- Esempi:
  - Se $L = \{aa\}$, allora $L^* = \{\epsilon, aa, aaaa, \ldots\} = \{a^{2n} \mid n \geq 0\}$ e $L^+ = \{a^{2n} \mid n \geq 1\}$
  - Se $L = \{a, aaa\}$, allora $L^* = \{\epsilon, a, aa, \ldots\} = \{a^n \mid n \geq 0\}$ e $L^+ = \{a^n \mid n \geq 1\}$
  - Se $L = \{aa, aaa\}$, allora $L^* = \{\epsilon, aa, aaa, \ldots\} = \{a^n \mid n \neq 1\}$ e $L^+ = \{a^n \mid n \geq 2\}$

Rappresentazione finita di linguaggi formali

Rappresentazione Finita dei Linguaggi

Se L è infinito, come lo possiamo rappresentare? E come possiamo determinare se una certa stringa $w \in L$? Proviamo con insiemi contabili a noi familiari:

1. $\mathbb{N} = \{0, 1, 2, 3, 4, ...\}$ infinito contabile (definito per elencazione!)
   - 1.1 Non possiamo memorizzare $\mathbb{N}$, servirebbe una memoria infinita.
   - 1.2 Possiamo trovare una rappresentazione finita implicita, ad esempio con gli assiomi di Peano, e definire $\mathbb{N}$ come il più piccolo insieme **generato** a partire da essi:

$$\frac{}{0 \in \mathbb{N}} \qquad \frac{x \in \mathbb{N}}{s(x) \in \mathbb{N}}$$

2. $\mathbb{P} = \{0, 2, 4, 6, ...\}$ infinito contabile
   - 2.1 Non possiamo memorizzare $\mathbb{P}$, ma
   - 2.2 possiamo trovare una rappresentazione finita implicita:

```
fun pari(x:integer):boolean
        pari := (x mod 2 = 0);
```

Il programma è una rappresentazione finita implicita della funzione booleana infinita che calcola (**riconosce** se $x \in \mathbb{P}$).

Rappresentazione Finita dei Linguaggi (2)

Esistono due tecniche

1. **Generativo/Sintetico**: linguaggio come insieme delle stringhe generate da una struttura finita chiamata **grammatica** (a struttura di frase)
2. **Riconoscitivo/Analitico**: linguaggio come insieme delle stringhe riconosciute da una struttura finita detta **automa**

Attenzione! Non tutti i linguaggi formali possono essere generati da grammatiche o riconosciuti da automi!

Non tutti i linguaggi formali sono finitamente rappresentabili

- A^* è equipotente a $\mathbb{N}$
- $L \subseteq A^*$ è contabile
- $\mathcal{P}(A^*)$ è l'insieme di tutti i linguaggi su alfabeto A, ma $\mathcal{P}(A^*)$ è equipotente a $\mathbb{R}$, l'insieme dei numeri reali!

Un qualunque formalismo è un linguaggio su alfabeto finito, per cui i suoi "programmi" (siano essi grammatiche o automi) sono al massimo tanti quanti i numeri naturali!
Ma se di grammatiche/automi su alfabeto A ce ne sono tanti quanti $\mathbb{N}$, e se i linguaggi su A sono tanti quanto $\mathbb{R}$, allora tantissimi linguaggi non possono essere rappresentati finitamente!
(Che $\mathbb{R}$ abbia una cardinalità superiore a $\mathbb{N}$ l'aveva dimostrato Georg Cantor.)

Argomento diagonale di Cantor

$Ling \backslash A^*$	w_1	w_2	w_3	w_4	w_5	$\cdots$
$L(G_1)$	X		X		X	$\cdots$
$L(G_2)$			X	X		$\cdots$
$L(G_3)$	X	X	X			$\cdots$
$L(G_4)$		X			X	$\cdots$
$L(G_5)$	X		X	X		$\cdots$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\ddots$

Supponiamo di avere un elenco di tutti i linguaggi generabili da grammatiche definite su alfabeto A.

Ad esempio, $L(G_1) = \{w_1, w_3, w_5, \ldots\}$ e $L(G_2) = \{w_3, w_4, \ldots\}$

Nota che $D = \{w_i | w_i \in L(G_i)\} = \{w_1, w_3, \ldots\}$ è il linguaggio diagonale.

Cosa si può dire del complemento della diagonale?

$$\overline{D} = \{w_i | w_i \notin L(G_i)\} = \{w_2, w_4, w_5, \ldots\}$$

Argomento diagonale di Cantor (2)

$\overline{D} = \{w_i | w_i \notin L(G_i)\}$ è un linguaggio, ma non esiste alcuna G_k tale che $\overline{D} = L(G_k)$ perché

- se $w_k \in L(G_k)$, allora $w_k \notin \overline{D}$
- se $w_k \notin L(G_k)$, allora $w_k \in \overline{D}$

Quindi $\overline{D}$ non compare nell'elenco dei linguaggi rappresentabili con una grammatica. Quindi l'elenco dei linguaggi generati da grammatiche su alfabeto A non è esaustivo.

(Nota che se anche aggiungessimo questo nuovo linguaggio all'elenco, potremmo ricalcolarci il nuovo linguaggio dato dal complemento della diagonale, che non sarebbe in elenco. Quindi, non c'è modo di elencare tutti i linguaggi formali su alfabeto A.)