Linguaggi di Programmazione

Grammatiche e derivazioni

Roberto Gorrieri

Alma Mater Studiorum - Università di Bologna

Generare linguaggi per mezzo di grammatiche

Definire finitamente un linguaggio

Proviamo a definire un linguaggio in modo finito e cominciamo col linguaggio di tutti i palindromi.
Un palindromo è una parola che letta da sinistra a destra è uguale a sè stessa letta da destra a sinistra. Ad esempio: "Abba", "Anna", "Emme", e in forma estesa anche "I topi non avevano nipoti", "Madam I'm Adam",...
Dato un alfabeto $A = \{a, b\}$, il linguaggio dei suoi palindromi è $L = \{\epsilon, a, b, aa, bb, aba, bab, aaa, bbb, abba, baab, aaaa, bbbb, ...\}$.
Esaminando questo insieme, si capisce che un palindromo può essere generato in questo modo:

- o è la stringa vuota ϵ
- oppure a
- oppure b
- oppure a $\langle$palindromo$\rangle$ a
- oppure b $\langle$palindromo$\rangle$ b

Esempio: palindromo

In Backus-Naur Form (BNF) si può descrivere come segue:

$$\langle P \rangle ::= \epsilon \mid a \mid b \mid a\langle P \rangle a \mid b\langle P \rangle b$$

dove il simbolo "::=" si legge come *può essere*, mentre il simbolo "|" si legge come *oppure*
Come grammatica:

$$P \longrightarrow \epsilon \mid a \mid b \mid aPa \mid bPb$$

È una definizione ricorsiva dove:

- P è detto "simbolo nonterminale"
- a, b sono detti "simboli terminali"
- $P \rightarrow aPa$ è una delle 5 "produzioni" (o regole) di questa grammatica (dove P è detta "testa" della produzione e aPa è detto "corpo" della produzione)

Esempio: palindromo (2)

Come insieme di assiomi e regole di inferenza:

$$\frac{}{\epsilon \in L(P)} \qquad \frac{}{a \in L(P)} \qquad \frac{}{b \in L(P)}$$

$$\frac{w \in L(P)}{awa \in L(P)} \qquad \frac{w \in L(P)}{bwb \in L(P)}$$

$L(P)$, il linguaggio generato a partire dal nonterminale P, è il più piccolo insieme generato da questi assiomi e regole di inferenza.

Esempio: Espressioni aritmetiche

Le espressioni aritmetiche che consideriamo in questo esempio sono quelle espressioni formate a partire dalle variabili "a" e "b" con gli operatori *, +, e parentesi (,). Una ⟨expr⟩ può essere:

- la variabile *a*
- oppure la variabile *b*
- oppure ⟨expr⟩ * ⟨expr⟩
- oppure ⟨expr⟩ + ⟨expr⟩
- oppure (⟨expr⟩)

In BNF:

$$\langle E \rangle ::= \ a \mid b \mid \langle E \rangle * \langle E \rangle \mid \langle E \rangle + \langle E \rangle \mid (\langle E \rangle)$$

Come grammatica:

$$E \longrightarrow \ a \mid b \mid E * E \mid E + E \mid (E)$$

Come derivare una stringa?

$$P \longrightarrow \epsilon \mid a \mid b \mid aPa \mid bPb$$

Si parte da P e si applicano le produzioni. Ad esempio, "abba" è un palindromo perché posso derivarlo a partire da P:

$$P \underbrace{\Rightarrow}_{P \to aPa} aPa \underbrace{\Rightarrow}_{P \to bPb} abPba \underbrace{\Rightarrow}_{P \to \epsilon} abba$$

Cioè $P \Rightarrow^* abba$ (procedimento di riscrittura che ad ogni passo rimpiazza la P, come specificato da una sua produzione, fino ad ottenere la stringa $abba$)

Usando assiomi e regole di inferenza:

$$\dfrac{\dfrac{\dfrac{}{\epsilon \in L(P)}}{bb = b\epsilon b \in L(P)}}{abba = ab\epsilon ba \in L(P)}$$

Come derivare una stringa? (2)

$$P \longrightarrow \epsilon \mid a \mid b \mid aPa \mid bPb$$

Si parte da P e si applicano le produzioni. Ad esempio, "bbabb" è un palindromo perché:

$$P \underbrace{\Rightarrow}_{P \to bPb} bPb \underbrace{\Rightarrow}_{P \to bPb} bbPbb \underbrace{\Rightarrow}_{P \to a} bbabb$$

Cioè $P \Rightarrow^* bbabb$

Usando assiomi e regole di inferenza:

$$\dfrac{\dfrac{\dfrac{}{a \in L(P)}}{bab \in L(P)}}{bbabb \in L(P)}$$

Altro esempio

$$E \longrightarrow a \mid b \mid E * E \mid E + E \mid (E)$$

Come dimostrare che $a + (a * b) \in L(E)$?

$$E \Rightarrow E + E \Rightarrow a + E \Rightarrow a + (E) \Rightarrow a + (E * E) \Rightarrow a + (a * E) \Rightarrow a + (a * b)$$

Usando assiomi e regole di inferenza:

$$\dfrac{\dfrac{}{a \in L(E)} \qquad \dfrac{\dfrac{\dfrac{}{a \in L(E)} \quad \dfrac{}{b \in L(E)}}{a * b \in L(E)}}{(a * b) \in L(E)}}{a + (a * b) \in L(E)}$$

Grammatiche

- Tante classi di grammatiche:
  - *regolari*
  - *libere (da contesto)*
  - *dipendenti dal contesto*
  - *monotone*
  - *generali* (o "a struttura di frase").
- Tutte seguono lo stesso pattern, differenziandosi solo per come sono caratterizzate le produzioni (o regole). Le vedremo tutte quante in seguito (classificazione di Chomsky)

Quelle più utili (rapporto tra espressività e facilità di analisi) sono le grammatiche libere (da contesto).

Grammatica libera da contesto
Una **grammatica libera da contesto** (o semplicemente grammatica libera) è una quadrupla (NT, T, R, S) dove:

- NT è un insieme finito di simboli nonterminali (di solito lettere maiuscole $A, B, ...$)
- T è un insieme finito di simboli terminali (detto anche "alfabeto", di solito lettere minuscole $a, b, ...$)
- $S \in NT$ è il simbolo iniziale
- R è un insieme finito di produzioni (o regole) della forma $V \to \alpha$ dove $V \in NT$ (detta *testa*) e $\alpha \in (T \cup NT)^*$ (detto *corpo*)

Esempi di grammatiche

- $G = (\{S\}, \{a, b, +, *\}, R, S\}$ con
  $R = \{S \xrightarrow{1} a, S \xrightarrow{2} b, S \xrightarrow{3} S + S, S \xrightarrow{4} S * S\}$
  Più rapidamente:
  $$S \to a \mid b \mid S + S \mid S * S$$
- $G_1 = (\{S, A\}, \{a, b\}, R_1, S\}$ con
  $R_1 = \{S \xrightarrow{1} aAb, A \xrightarrow{2} aAb, A \xrightarrow{3} \epsilon\}$
  Più rapidamente:
  $$S \to aAb$$
  $$A \to aAb \mid \epsilon$$

N.B.: R è un insieme, numeriamo le produzioni per dare loro un "nome", non per ordinarle.

Esempi di grammatiche

- $G_2 = (\{S, A, B\}, \{a, b\}, R_2, S\}$ con
  $R_2 = \{S \xrightarrow{1} AB, A \xrightarrow{2} aA, A \xrightarrow{3} a, B \xrightarrow{4} bB, B \xrightarrow{5} b\}$
  Più rapidamente:
  $$S \to AB$$
  $$A \to aA \mid a$$
  $$B \to bB \mid b$$
- $G_3 = (\{S\}, \{a, b\}, R_3, S\}$ con
  $R_3 = \{S \xrightarrow{1} aSb, S \xrightarrow{2} ab\}$
  Più rapidamente:
  $$S \to aSb \mid ab$$

Altro esempio

$$E \to I \mid E + E \mid E * E \mid -E \mid (E)$$
$$I \to a \mid b \mid Ia \mid Ib$$

- $L(I) = \{a, b\}^+$, ovvero qualunque sequenza non vuota di "a" e "b"
- $L(I)$ è il linguaggio degli identificatori (un insieme infinito contabile).
- $L(E)$ è il linguaggio delle espressioni aritmetiche costruite sugli identificatori (pure un insieme infinito contabile).
- Cioè I genera il "lessico" (identificatori) che E può usare per costruire le espressioni aritmetiche

Esempio in cui il "lessico" può essere infinito contabile.

Derivazioni

Data $G = (NT, T, R, S)$ libera da contesto, diciamo che da v si ricava immediatamente w (o anche "v si riscrive in un passo in w"), e lo denotiamo con $v \Rightarrow w$, se con $x, y, z \in (T \cup NT)^*$:

$$\frac{v = xAy \qquad (A \to z) \in R \qquad w = xzy}{v \Rightarrow w}$$

Diciamo che da v si deriva w (o "v si riscrive in w"), e lo denotiamo con $v \Rightarrow^* w$, se esiste una sequenza finita (eventualmente vuota) di derivazioni immediate

$$v \Rightarrow w_0 \Rightarrow w_1 \Rightarrow \ldots \Rightarrow w,$$

cioè $\Rightarrow^*$ è la chiusura riflessiva e transitiva della relazione $\Rightarrow$:

$$\frac{-}{v \Rightarrow^* v} \qquad \frac{v \Rightarrow^* w \quad w \Rightarrow z}{v \Rightarrow^* z}$$

Esempi di derivazioni

1. $G = S \to a \mid b \mid S + S \mid S * S$
   $S + \underline{S} \Rightarrow S + \underline{S} * S \Rightarrow \underline{S} + a * S \Rightarrow S * S + a * S$
   (sottolineo il nonterminale che sto per riscrivere)
   cioè $S + S \Rightarrow^* S * S + a * S$
2. $G_1 = S \to aAb$ e $A \to aAb \mid \epsilon$
   $\underline{A}A \Rightarrow a\underline{A}bA \Rightarrow abA \Rightarrow abaAb \Rightarrow abab$
   cioè $AA \Rightarrow^* abab$
   (nota che AA non si deriva dal simbolo iniziale S)
3. $G_2 = S \to AB$ e $A \to aA \mid a$ e $B \to bB \mid b$
   $S \Rightarrow A\underline{B} \Rightarrow Ab\underline{B} \Rightarrow Abb \Rightarrow abb$
   cioè $S \Rightarrow^* abb$
   ma anche $S \Rightarrow \underline{A}B \Rightarrow aB \Rightarrow abB \Rightarrow abb$

N.B.: Quest'ultimo esempio mostra che ci possono essere più derivazioni diverse che generano la stessa stringa.

Linguaggio generato
Il **linguaggio generato** da una grammatica libera da contesto $G = (NT, T, R, S)$ è l'insieme

$$L(G) = \{w \in T^* | S \Rightarrow^* w\}$$

Notare che si parte dal simbolo iniziale S e le parole w sono formate solo da terminali.

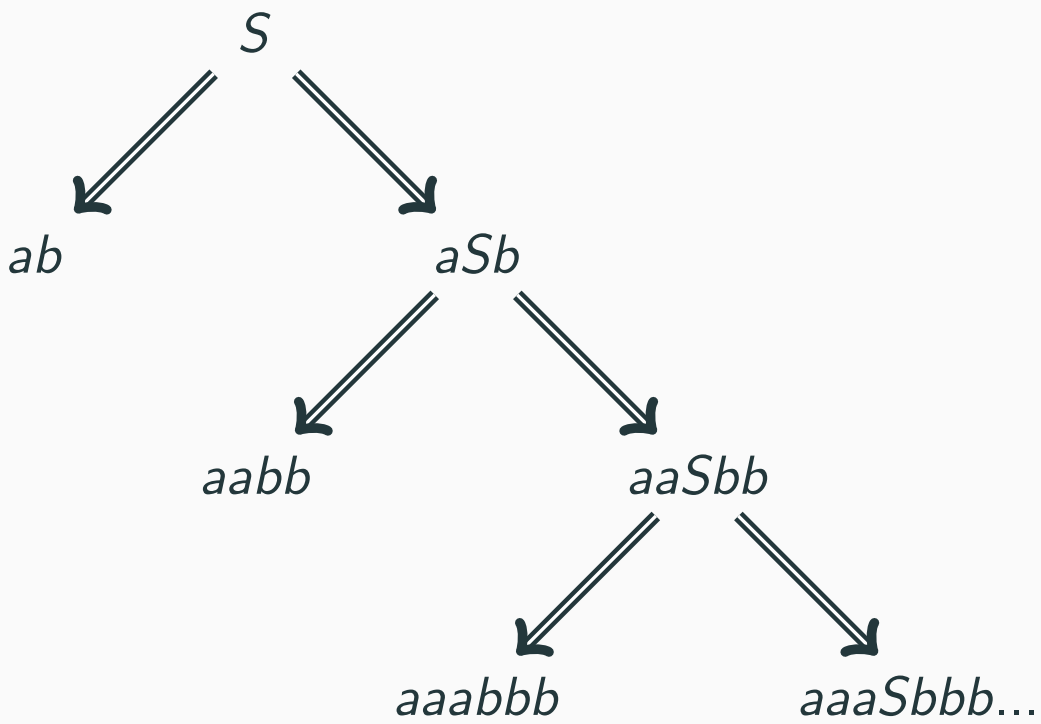
Data G, come faccio a determinare $L(G)$? E a verificare se $w \in L(G)$?

- studieremo tecniche opportune che in alcuni casi saranno anche efficienti;
- algoritmo "naive": partire da S e provare ad applicare in tutti i modi possibili le produzioni per trovare una derivazione che generi w (nondeterminismo $\rightarrow$ backtracking).

In alcuni casi, tale verifica è semplice.

Esempio (1)

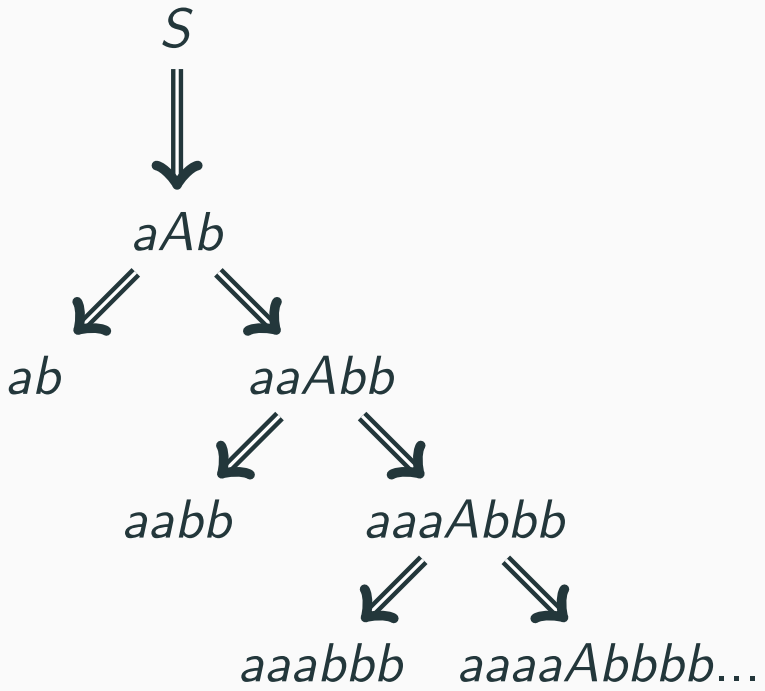
$$G_3 = S \to aSb \mid ab$$



È chiaro che $L(G_3) = \{a^n b^n | n \geq 1\}$

Esempio (2)

$$G_1 = S \to aAb \quad \text{e} \quad A \to aAb \mid \epsilon$$



È chiaro che $L(G_1) = \{a^n b^n | n \geq 1\}$

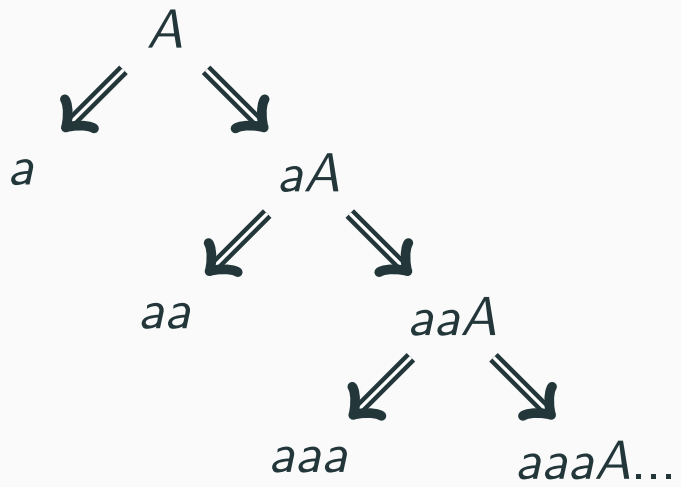
G_1 e G_3 sono due grammatiche equivalenti perché $L(G_1) = L(G_3)$.

In generale, esistono infinite grammatiche diverse che generano lo stesso linguaggio. Perché?

Esempio (3)

$$G_2 = S \to AB \quad \text{e} \quad A \to aA \mid a \quad \text{e} \quad B \to bB \mid b$$

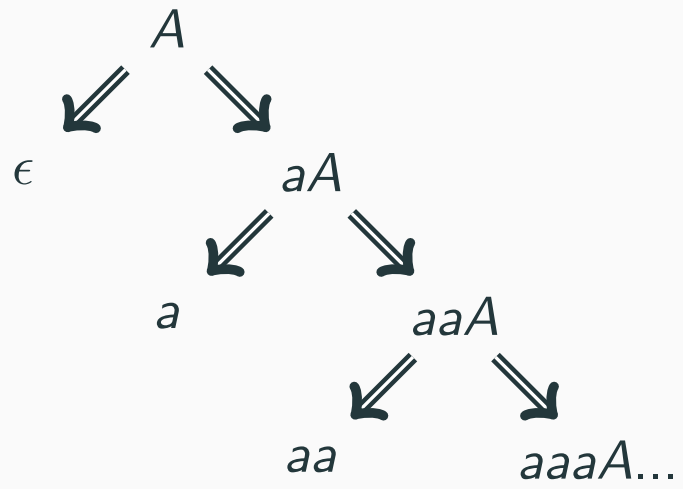
$$L(G_2) = L(A) \cdot L(B)$$



È chiaro che $L(A) = \{a^n | n \geq 1\}$. Similmente, $L(B) = \{b^n | n \geq 1\}$.
Per cui $L(G_2) = L(A) \cdot L(B) = \{a^n b^m | n, m \geq 1\}$.

Esempio (4)

$$G_4 = S \to AB \text{ e } A \to aA \mid \epsilon \quad \text{e } B \to bB \mid \epsilon$$
$$L(G_4) = L(A) \cdot L(B)$$

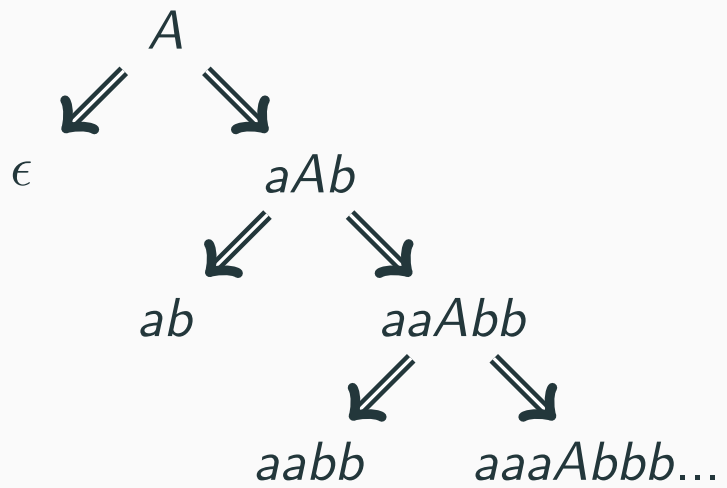


È chiaro che $L(A) = \{a^n | n \geq 0\}$. Similmente, $L(B) = \{b^n | n \geq 0\}$.
Per cui $L(G_4) = L(A) \cdot L(B) = \{a^n b^m | n, m \geq 0\}$.

N.B.: $a^0 b^0 = \epsilon \in L(G_4)$ perché $S \Rightarrow AB \Rightarrow B \Rightarrow \epsilon$.

Esempio (5)

$$G_5 = S \to AB \quad \text{e} \quad A \to aAb \mid \epsilon \quad \text{e} \quad B \to bB \mid \epsilon$$
$$L(G_5) = L(A) \cdot L(B)$$



È chiaro che $L(A) = \{a^n b^n | n \geq 0\}$, mentre $L(B) = \{b^n | n \geq 0\}$.
Per cui $L(G_5) = L(A) \cdot L(B) = \{a^n b^{n+m} | n, m \geq 0\} = \{a^n b^m | m \geq n \geq 0\}$.

E all'incontrario?

- E all'incontrario, dato un linguaggio L, come determinare una grammatica G che lo genera?
  (Ricordate che non tutti i linguaggi sono generabili per mezzo di grammatiche.)
- Serve creatività: bisogna trarre ispirazione da esempi noti, per poter immaginare una soluzione.

Ad esempio: $L_1 = \{a^n b^m \mid n \geq m \geq 0\}$ assomiglia ad un linguaggio che abbiamo appena visto, quindi ....

$$S \to AB$$
$$A \to aA \mid \epsilon$$
$$B \to aBb \mid \epsilon$$

Esempi in reverse (1)

$$L_2 = \{a^{2n+1} \mid n \geq 0\} = \{a, aaa, aaaaa, \ldots\}$$

$$S \to a \mid aaS$$

oppure

$$S \to a \mid Saa$$

$$L_3 = \{a^{2n} b^{2m+1} \mid n, m \geq 0\}$$

$$S \to aaS \mid bB$$

$$B \to \epsilon \mid bbB$$

oppure

$$S \to AB$$

$$A \to \epsilon \mid aaA$$

$$B \to b \mid bbB$$

N.B.: Ci possono essere tante diverse grammatiche che generano lo stesso linguaggio. Quante?

Esempi in reverse (2)

Un caso banale: $L_4 = \{ab, ac, ad\}$ è un linguaggio finito.

$$S \to ab \mid ac \mid ad$$

oppure (usando fattorizzazione)

$$S \to aA$$

$$A \to b \mid c \mid d$$

$$L_5 = \{a^{2n} b^m c^{2m} \mid n \geq 0, m \geq 1\}$$

$$S \to aaS \mid bBcc$$

$$B \to \epsilon \mid bBcc$$

oppure

$$S \to AB$$

$$A \to \epsilon \mid aaA$$

$$B \to bcc \mid bBcc$$

Esempi in reverse (3)

$$L_6 = \{a^n b^k c^n \mid n \geq 0, k \geq 1\}$$
$$S \to aSc \mid B$$
$$B \to b \mid bB$$

$$L_7 = \{a^n b^n c^m d^m \mid n, m \geq 0\}$$
$$S \to AB$$
$$A \to \epsilon \mid aAb$$
$$B \to \epsilon \mid cBd$$

$$L_8 = \{a^n b^m c^m d^n \mid n, m \geq 0\}$$
$$S \to \epsilon \mid aSd \mid bAc$$
$$A \to \epsilon \mid bAc$$

Esempi in reverse (4)

$$L_9 = \{w \in \{a,b\}^* \mid \exists x \in \{a,b\}^*.w = xaa\}$$
$$S \to aS \mid bS \mid aa$$

$$L_{10} = \{w \in \{(,)\}^* \mid \text{in } w \text{ tutte le parentesi sono bilanciate}\}$$
$$S \to \epsilon \mid (S) \mid SS$$

$$L_{11} = \{w \in \{a,b\}^* \mid \text{in } w \text{ occorrono tante } a \text{ quante } b\}$$
$$S \to \epsilon \mid aSb \mid bSa \mid SS$$

$L_{12} = \{ww^R \mid w \in \{a,b\}^*\}$ è il linguaggio dei palindromi di lunghezza pari, dove $\epsilon^R = \epsilon$ e $(aw)^R = w^R a$

$$S \to \epsilon \mid aSa \mid bSb$$

Esempi in reverse (5)

$$L_{13} = \{w \in \{a, b\}^* \mid \text{in } w \text{ le "}a\text{" sono dispari e le "}b\text{" sono pari}\}$$

$$S \to aB \mid bA$$
$$B \to aS \mid bC \mid \epsilon$$
$$A \to aC \mid bS$$
$$C \to aA \mid bB$$

Ogni nonterminale "codifica" uno "stato":

$S = a$ pari e b pari

$B = a$ dispari e b pari (condizione di appartenenza a L_{13}, per cui c'è la produzione epsilon che fa sparire B)

$C = a$ dispari e b dispari

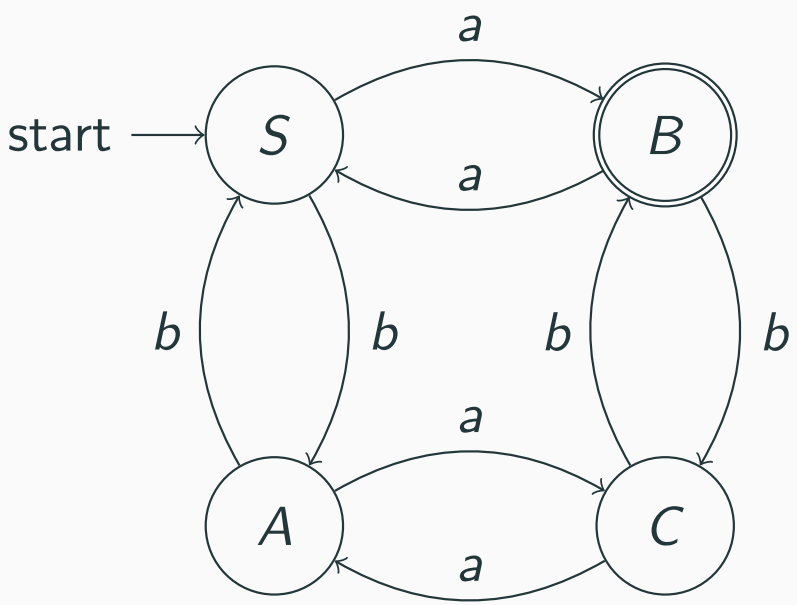
$A = a$ pari e b dispari

Facilmente rappresentabile per mezzo di un automa finito.

Automa DFA per L_{13}

$$L_{13} = \{w \in \{a, b\}^* \mid \text{in } w \text{ le "}a\text{" sono dispari e le "}b\text{" sono pari}\}$$

$$S \to aB \mid bA$$
$$B \to aS \mid bC \mid \epsilon$$
$$A \to aC \mid bS$$
$$C \to aA \mid bB$$



Esempi in reverse (6)

$$L_{14} = \{a^n b^m c^k \mid n = m + k, n, m, k \geq 0\}$$
$$S \to aSc \mid aBb \mid \epsilon$$
$$B \to aBb \mid \epsilon$$

Esercizi (non banali):
Provate a trovare una grammatica che genera il linguaggio L_{15} (hard!) e una per L_{16} (smart!)

- $L_{15} = \{a^n b^m a^p b^q \mid n + m = p + q, n, m, p, q \geq 0\}$
- $L_{16} = \{a^n b^m b^n a^m \mid n, m \geq 0\}$